Tomasz Tomala
Podstawy Sztucznej Inteligencji
Sprawozdanie z projektu nr 1

Celem ćwiczenia buło poznanie budowy i działania perceptronu poprzez implementację oraz uczenie perceptronu realizującego wybraną funkcję logiczną dwóch zmiennych.

1) Syntetyczny opis budowy wykorzystanego algorytmu uczenia:

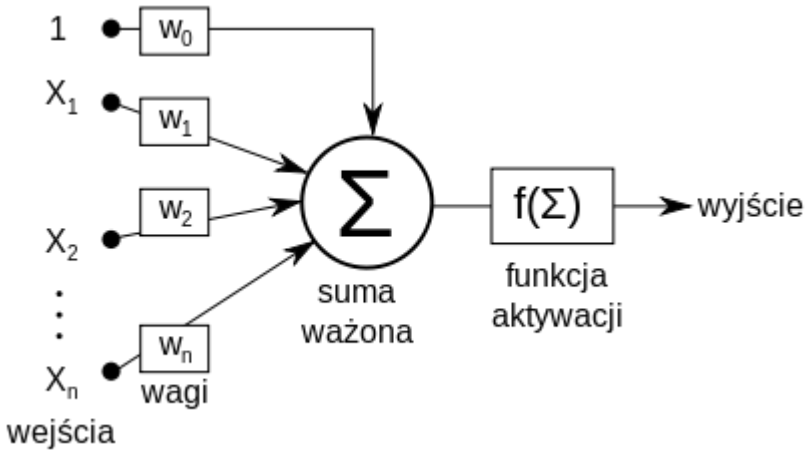

Ilustracja 1: Model perceptronu McCullocha-Pittsa

Do budowy perceptronu wykorzystałem podany na wykładzie model McCullocha-Pittsa. Zaimplementowana przeze mnie klasa Perceptron składa się z trzech metod: active, process oraz learn.
Metoda ***active*** wykorzystuje unipolarną funkcję progową która zwraca wynik 0 lub 1 dla podanego argumentu.
Metoda ***process*** sumuje iloczyn sygnałów wejściowych i odpowiadających im wag. Uruchamia metodę activate z otrzymaną sumą iloczynów jako parametrem, oraz zwraca wynik tej metody.
Metoda ***learn*** wywołuje metodę process dla otrzymanych wejść jako parametrów, po czym na podstawie otrzymanego wyniku modyfikuje wszystkie wagi dla odpowiednich wejść.

2) Zestawienie otrzymanych wyników:

Do uczenia perceptronu wybrałem funkcję logiczną AND.
Na początku zacząłem uczyć perceptron w taki sposób, że przesyłałem mu wszystkie kombinacje danych wejściowych taką samą ilość razy. Wszystkie wagi początkowe ustawiłem na wartość równą 0.5. Z kolei współczynnik uczenia się ustawiłem na wartość 0.01. Proces uczenia wymagał 28 powtórzeń. Poniżej prezentacja na wykresie:

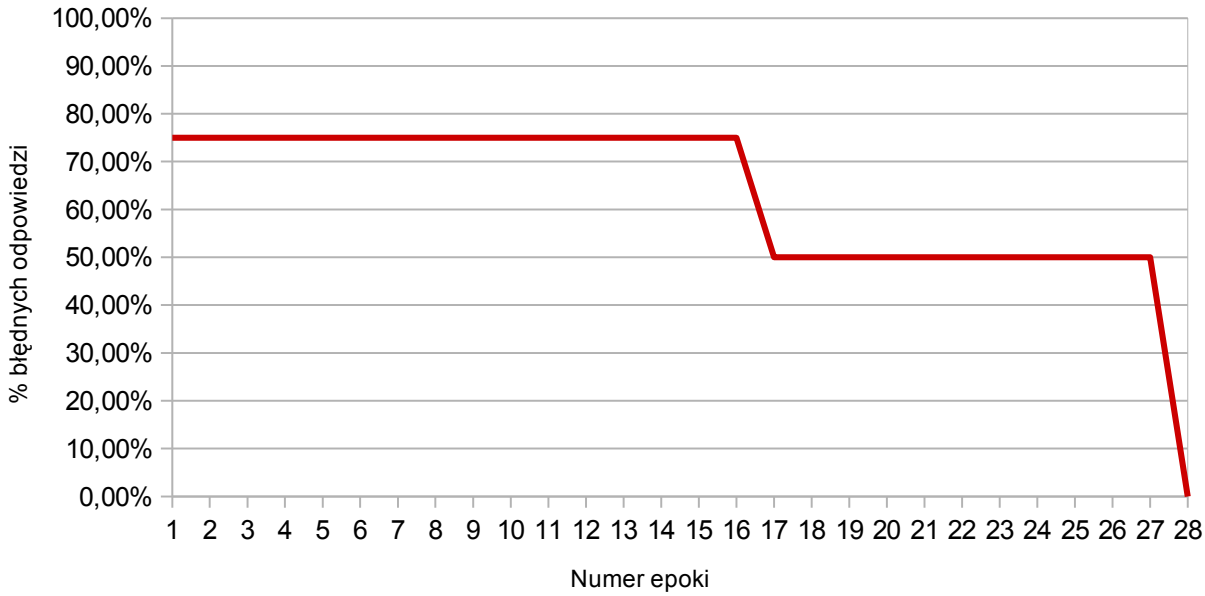

Następnie zacząłem eksperymentować z różnymi wagami początkowymi. W każdym kolejnym teście sprawdzałem jak długo zajmie nauka w zależności od wag początkowych. Warunki testu identyczne jak do tego powyżej. Poniżej wyniki:

Waga początkowa	Ilość powtórzeń
0	5
0.05	3
0.08	5
0.13	8
0.17	10
0.2	11

Kolejnym krokiem było sprawdzenie jak będzie wyglądał proces uczenia się dla różnych współczynników uczenia się. Test taki sam jak powyżej, jednak wagi początkowe są równe 0.5. Poniżej przedstawiam wyniki:

Współczynnik uczenia	Ilość powtórzeń
0.01	28
0.1	3
0.5	5
1.2	1
5	5

Następnie sprawdziłem jak będą wyglądać wyniki dla różnej ilości danych uczących. Tym razem jednak ustaliłem stałą wartość dla wszystkich wag początkowych równą 0.5 a współczynnik uczenia wynosił 0.1. Poniżej przedstawiam wyniki dla różnych kombinacji danych wejściowych i ilości ich powtórzeń:

x1	x2	Ilość powtórzeń	wynik	x1	x2	Ilość powtórzeń	wynik
0	0	1	błędny	0	0	2	błędny
0	1	1		0	1	2	
1	0	1		1	0	2	
1	1	1		1	1	2	

x1	x2	Ilość powtórzeń	wynik	x1	x2	Ilość powtórzeń	wynik
0	0	4	poprawny	0	0	4	poprawny
0	1	3		0	1	3	
1	0	2		1	0	2	
1	1	1		1	1	0	

x1	x2	Ilość powtórzeń	wynik
0	0	6	poprawny
0	1	3	
1	0	1	
1	1	0	

3) Analiza i dyskusja błędów uczenia i testowania opracowanego perceptronu w zależności od wartości współczynnika uczenia oraz liczby danych uczących:

Uczenie się perceptronu zależy od trzech czynników: wag początkowych, współczynnika uczenia oraz od danych uczących. Jak widać na powyższych danych, wagi początkowe wpływają na szybkość uczenia się jednak współczynnik uczenia wpływa na to o wiele bardziej, ponieważ wagi i tak ulegają ciągłej modyfikacji. Jednak w głównej mierze to od danych uczących zależy czy perceptron będzie w stanie się nauczyć czy też nie, co wyraźnie widać na ostatnim teście. W przypadku funkcji logicznej AND nie musiałem podawać perceptronowi do nauczenia się danych wejściowych [1,1] ani razu, jednak musiałem go nauczyć pozostałych trzech kombinacji odpowiednią ilość razy, w przeciwnym wypadku wynik był błędny.

4) Sformułowanie wniosków:

Dla pojedynczego perceptronu proces uczenia jest bardzo prosty. Jesteśmy w stanie nauczyć go prostej funkcji logicznej w zaledwie kilku krokach. Całość opiera się o wykonywanie tych samych operacji dla różnych danych wejściowych i odpowiednim modyfikowaniu wag.
W całym procesie uczenia się najważniejsze są dane uczące. Należy dobrać je w odpowiedni sposób i powtórzyć uczenie się na ich podstawie odpowiednią ilość razy. W przeciwnym wypadku wyniki będą niepoprawne. Wagi początkowe również wpływają na proces uczenia, jednak mają one raczej marginalne znaczenie. O wiele większe znaczenie ma współczynnik uczenia. Jeżeli wybierzemy za mały, to perceptronowi zajmie bardzo długo, aż uzyskamy odpowiednie wyniki. Z kolei za duża wartość tego współczynnika może sprawić, że nie będziemy w stanie w ogóle trafić w odpowiednie wagi, lub też zajmie to bardzo dużo czasu. Dlatego właśnie musimy dokonać optymalnego wyboru współczynnika uczenia.

5) Listing całego kodu

```java
package perceptron;

import java.util.Random;

public class Perceptron {

    private int noi; //ilość wejść
    private double[] w; //wagi

    public Perceptron ( int numbers_of_inputs ) {
        noi = numbers_of_inputs;
        w = new double[noi];

        for ( int i = 0; i < noi; i++ )
            w[i] = new Random().nextDouble(); //wagi początkowe są losowane
    }

    //funkcja aktywująca
    private int active ( double y_p ) {
        return y_p < 0 ? 0 : 1;
    }

    //sumator
    public int process ( int[] x ) {
        double y_p = 0;

        for ( int i = 0; i < noi; i++ )
            y_p += x[i] * w[i];

        return active( y_p );
    }

    //uczenie
    public void learn ( int[] x, double y, double lr ) {
        double y_p = process( x );

        for ( int i = 0; i < noi; i++ )
            w[i] += ( y - y_p ) * lr * x[i];
    }

    public double getW ( int i ) {
        return w[i];
    }
}
```

```java
package perceptron;

import java.util.Arrays;

public class Main {

    public static void main ( String[] args ) {

        int number_of_inputs = 3;
        Perceptron perc = new Perceptron( number_of_inputs );

        int n = 0; //licznik ilości epok uczenia się
        int r = 4; //rozmiar tablic danych wejściowych
        double learning_rate = 0.1; //krok uczenia się
        int x0 = 1; //bias

        int[] x1 = { 0, 0, 1, 1 }; //dane wejściowe do AND
        int[] x2 = { 0, 1, 0, 1 };

        int[] y = { 0, 0, 0, 1 }; // dane oczekiwane do AND
        int[] wyj = new int[4]; //tablica przechowująca wyniki testowania perceptronu

        //uczenie perceptronu
        while ( ! Arrays.equals( y, wyj ) ) {
            for ( int i = 0; i < r; i++ )
                perc.learn( new int[] { x0, x1[i], x2[i] }, y[i], learning_rate );

            for ( int i = 0; i < r; i++ )
                wyj[i] = perc.process( new int[] { x0, x1[i], x2[i] } );

            n++;
        }
        System.out.println( "Ilość kroków do nauczenia się = " + n );
    }
}
```

Bibliografia:

https://pl.wikipedia.org/wiki/Neuron_McCullocha-Pittsa