

Celem ćwiczenia było poznanie budowy i działania sieci Kohonena przy wykorzystaniu reguły WTA do odwzorowania istotnych cech kwiatów.

1) Syntetyczny opis budowy użytej sieci i algorytmów uczenia

Reguła Kohonena opiera się na mechanizmie współzawodnictwa między neuronami.

Wagi każdego neuronu tworzą wektor $\mathbf{w}_i = [w_{i1}, w_{i2}, \dots, w_{iN}]^T$. Przy założeniu normalizacji wektorów wejściowych, we współzawodnictwie wygrywa neuron, którego wagi najmniej różnią się od odpowiednich składowych tego wektora. Zwycięski neuron spełnia relację:

$$d(\mathbf{x}, \mathbf{w}_w) = \min_{1 \leq i \leq n} d(\mathbf{x}, \mathbf{w}_i)$$

Gdzie $d(\mathbf{x}, \mathbf{w})$ oznacza odległość w sensie wybranej metryki między wektorem \mathbf{x} i wektorem \mathbf{w} a n to ilość neuronów. Podczas ćwiczenia do obliczania odległości między wektorami użyłem miary według normy L_1 (Mahnattan):

$$d(\mathbf{x}, \mathbf{w}_i) = \sqrt{\sum_{j=1}^N |x_j - w_{ij}|}$$

W strategii WTA zmiana wag dotyczy tylko neuronu zwycięzcy wg zależności:

$$\mathbf{w}_i(k+1) = \mathbf{w}_i(k) + \eta_i(k)[\mathbf{x} - \mathbf{w}_i(k)]$$

Neurony przegrywające konkurencję nie zmieniają swoich wag.

Ważną rolę odgrywa nadmiarowość danych uczących. Wielokrotne powtórzenia podobnych wzorców stanowią „bazę wiedzy”, z której odpowiednią drogą wyciągane są wnioski decyzyjne. Do uczenia sieci użyłem zestawu danych istotnych cech kwiatów zaczerpniętych z Wikipedii. Były to wektory złożone z czterech składowych, które poddałem procesowi normalizacji. Normalizacja polega na podzieleniu każdej ze składowej wektora przez długość tego wektora:

$$\hat{\mathbf{u}} = \frac{\vec{\mathbf{u}}}{\|\vec{\mathbf{u}}\|}$$

Dane uczące zostały poddane normalizacji, ponieważ istnieje taka potrzeba przy małych wymiarach przestrzeni, np. $n = 2$, $n = 3$. Jeśli jednak chodzi o wektory wag neuronów, to nie musiały one być już później normalizowane w procesie uczenia, ponieważ przy znormalizowanych wektorach uczących \mathbf{x} , wektory wag – nadążając za nimi – stają się automatycznie znormalizowane.

Dodatkowo podczas ćwiczenia użyłem sporej nadmiarowości jeśli chodzi o ilość neuronów. Było to konieczne, ponieważ inicjalizacja wag sieci jest losowa, tak więc część neuronów można znaleźć się w strefie, w której nie ma danych lub ich liczba jest znikoma. Neurony takie mają niewielkie szanse na zwycięstwo i zwane są neuronami martwymi.


2) Zestawienie otrzymanych wyników

Jako dane uczące wykorzystałem zestaw istotnych cech kwiatów, które zaczerpnąłem z Wikipedii. Każdy kwiat to wektor składający się z czterech składowych. Do nauki wybrałem 15 kwiatów dla każdego z 3 gatunków. Do testowania wybrałem po 5 kwiatów dla każdego gatunku. Uczenie przeprowadziłem po 10 razy dla 3 różnych współczynników uczenia: 0.1, 0.01 oraz 0.001. W procesie uczenia brało udział 200 neuronów. Poniżej przedstawiam wyniki:


LP	Współczynnik uczenia	0,1	0,01	0,001
1	% Poprawności testowania	100,00%	93,33%	93,33%
	Liczba epok	2	6	230
2	% Poprawności testowania	100,00%	100,00%	100,00%
	Liczba epok	3	17	250
3	% Poprawności testowania	100,00%	100,00%	100,00%
	Liczba epok	1	32	263
4	% Poprawności testowania	100,00%	100,00%	100,00%
	Liczba epok	9	23	725
5	% Poprawności testowania	100,00%	100,00%	100,00%
	Liczba epok	1	22	169
6	% Poprawności testowania	100,00%	100,00%	100,00%
	Liczba epok	2	10	1248
7	% Poprawności testowania	100,00%	100,00%	100,00%
	Liczba epok	6	19	118
8	% Poprawności testowania	100,00%	100,00%	100,00%
	Liczba epok	3	26	156
9	% Poprawności testowania	100,00%	100,00%	100,00%
	Liczba epok	10	18	868
10	% Poprawności testowania	100,00%	100,00%	100,00%
	Liczba epok	4	6	123

Współczynnik uczenia	0,1	0,01	0,001
Min % poprawności	100,00%	93,33%	93,33%
Max % poprawności	100,00%	100,00%	100,00%
Średni % poprawności	100,00%	99,33%	99,33%
Min liczba epok	1	6	118
Max liczba epok	10	32	1248
Średnia liczba epok	4,1	17,9	415


Min % poprawności testowania w zależności od współczynnika uczenia




Max % poprawności testowania w zależności od współczynnika uczenia




Średni % poprawności testowania w zależności od współczynnika uczenia




Min liczba epok testowania w zależności od współczynnika uczenia



Max liczba epok testowania w zależności od współczynnika uczenia



Średnia liczba epok testowania w zależności od współczynnika uczenia



3) Analiza i dyskusja błędów uczenia i testowania oraz wyłonionych cech dla wyników opracowanej sieci w zależności od wartości współczynnika uczenia

Jak widać na powyższych wynikach, ilość epok jaka była potrzebna do nauczania sieci znacząco różniła się w poszczególnych przypadkach. Wyniki te różniły się o wiele rzędów wielkości. Tak więc jeśli chodzi o szybkość uczenia, widać, że nie jest to dobra miara ocenienia jakości uczenia sieci, gdyż jest to spowodowane wyłącznie początkowymi wartościami wag neuronów, a te są losowe. Jeśli jednak spojrzeć na wykresy, to widać, że zarówno jeśli chodzi o wartości maksymalne, minimalne czy też średnie, wraz ze wzrostem współczynnika uczenia, wartość liczby epok potrzebnych do nauczania sieci stale spada.

Jeśli chodzi o dobór współczynnika uczenia, to ma on jednak znaczenie. Na powyższych wynikach widać, że najlepsze wyniki uzyskane zostały przy współczynniku uczenia równym 0.1, gdzie poprawność testowania danych zawsze wynosiła 100%. W pozostałych dwóch przypadkach zdarzyły się przypadki gdzie podczas testowania zdarzyły się błędy, a poprawność wynosiła 93.33%.

4) Sformułowanie wniosków

Na podstawie powyższych wyników można wnioskować, iż najlepsze wyniki można uzyskać stosując wyższy współczynnik uczenia, ponieważ sieć ze współczynnikiem uczenia równym 0.1 zawsze uzyskiwała 100% skuteczności podczas testowania. Działo się tak dlatego, że większy współczynnik uczenia oznacza szybsze zbliżanie się do siebie wektorów po modyfikacji wag zwycięskiego neuronu. Jednak oczywiście zbyt duży współczynnik uczenia może negatywnie wpłynąć na wyniki.

Bardzo ważnym elementem całego procesu była normalizacja danych uczących. Dane tak naprawdę są wektorami N-wymiarowymi, a sam proces uczenia polega na wyłonieniu neuronu, którego wektor wag jest najbliższy do zadanego wektora uczącego, po czym następuje modyfikacja wag tego neuronu, w taki sposób, aby odległość między wektorami uległa zmniejszeniu. Jeśli dane nie byłyby znormalizowane to sam proces uczenia nie miał by sensu. Zwycięzcą prawie zawsze byłby ten sam neuron, ponieważ początkowe wagi neuronów mieszczą się w zakresie $<0, 1>$. Tak więc w przypadku gdzie wektory uczące są w przestrzeni N-wymiarowej oddalone w znacznej odległości od wektorów wagowych neuronów, to pierwszy neuron zwycięzca po modyfikacji swojego wektora wag zbliżyłby się do wektorów uczących pozostawiając całą resztę neuronów w tyle, a w każdej kolejnej epoce to właśnie on byłby wyłoniony jako zwycięzca. Należało więc znormalizować dane, tak aby wektory wag wszystkich neuronów znajdowały się w otoczeniu danych uczących od samego początku.

W odniesieniu do powyższego, ważna również była sama ilość neuronów. Zbyt mała liczba mogłaby doprowadzić do tego, że tylko jeden neuron byłby zwycięzcą, a reszta neuronów pozostałaby martwa. Z kolei zbyt duża ilość neuronów mogłaby doprowadzić do tego, że dane zostałyby skategoryzowane nie jako 3 zbiory, ale jako większa liczba zbiorów. Należało więc metodą prób i błędów określić odpowiednią liczbę neuronów.

Jeśli chodzi o sam proces testowania, to widać, iż podczas testów rzadko pojawiał się jakiś błąd. Zawdzięczamy to odpowiedniej ilości danych uczących. Jeśli danych byłoby zbyt mało, to podczas testowania zwycięskim neuronem mógłby się okazać neuron, który podczas uczenia został wyłoniony jako zwycięzca dla innego zbioru kwiatów.

5) Listing z komentarzami całego kodu programu

```
package main;

public class Flower {

    //rozmiar tablicy to: [3][39][4]
    public static double[][][] flowerLearn = {
        {
            { 0.809246635, 0.5446852351, 0.217874094, 0.0311248706 },
            { 0.8281328734, 0.5070201266, 0.2366093924, 0.0338013418 },
            { 0.8053330754, 0.5483118811, 0.2227517017, 0.0342694926 },
            { 0.8000302475, 0.5391508189, 0.2608794285, 0.0347839238 },
            { 0.7904706124, 0.5691388409, 0.2213317715, 0.0474282367 },
            { 0.7841749863, 0.5663486012, 0.2468699031, 0.058087036 },
            { 0.7801093557, 0.5766025673, 0.2374245865, 0.0508766971 },
            { 0.8021849185, 0.5454857446, 0.2406554756, 0.0320873967 },
            { 0.8064236562, 0.5315065006, 0.2565893451, 0.0366556207 },
            { 0.81803119, 0.5175299366, 0.2504177112, 0.0166945141 },
            { 0.8037351881, 0.5507074437, 0.2232597745, 0.0297679699 },
            { 0.7869910029, 0.5574519604, 0.2623303343, 0.0327912918 },
            { 0.8230721776, 0.514420111, 0.2400627185, 0.017147337 },
            { 0.802512559, 0.559892511, 0.2052939207, 0.0186630837 },
            { 0.8112086464, 0.5594542389, 0.1678362717, 0.0279727119 },
            { 0.7738111103, 0.5973278746, 0.2036345027, 0.0543025341 },
            { 0.794289441, 0.5736534852, 0.1912178284, 0.0588362549 },
            { 0.8032741237, 0.5512665555, 0.2205066222, 0.047251419 },
            { 0.806828203, 0.5378854687, 0.2406329728, 0.0424646423 },
            { 0.7796488324, 0.5809148163, 0.2293084801, 0.045861696 },
            { 0.8173378965, 0.5146201571, 0.2573100785, 0.0302717739 },
            { 0.7859185787, 0.5701762238, 0.2311525231, 0.0616406728 },
            { 0.775770746, 0.6071249316, 0.1686458143, 0.0337291629 },
            { 0.8059779151, 0.5215151215, 0.268659305, 0.0790174427 },
            { 0.7761140001, 0.5497474167, 0.3072117917, 0.0323380833 },
            { 0.8264745061, 0.4958847037, 0.264471842, 0.0330589802 },
            { 0.7977820578, 0.5424917993, 0.2552902585, 0.0638225646 },
            { 0.806419649, 0.5427824561, 0.2326210526, 0.0310161403 },
            { 0.8160942667, 0.5336000975, 0.2197176872, 0.031388241 },
            { 0.7952406381, 0.5414404345, 0.2707202172, 0.0338400272 },
            { 0.8084658442, 0.5221341911, 0.2694886147, 0.0336860768 },
            { 0.8222502813, 0.5177131401, 0.2284028559, 0.0609074282 },
            { 0.7657831085, 0.6037905278, 0.2208989736, 0.0147265982 },
            { 0.7786744728, 0.5946241429, 0.1982080476, 0.0283154354 },
            { 0.8176894181, 0.5173137135, 0.2503130872, 0.0333750783 },
            { 0.8251229525, 0.5280786896, 0.1980295086, 0.0330049181 },
            { 0.826997544, 0.5262711644, 0.1954721468, 0.030072638 },
            { 0.7852322109, 0.5769052978, 0.2243520603, 0.0160251472 },
            { 0.8021241325, 0.5469028176, 0.236991221, 0.0364601878 }
        }, //setosa

        {
            { 0.7670110293, 0.3506336134, 0.5149931197, 0.1534022059 },
            { 0.7454975664, 0.3727487832, 0.5241779763, 0.1747259921 },
            { 0.7551928518, 0.3392895421, 0.536296373, 0.1641723591 },
            { 0.753849162, 0.3152460132, 0.548253936, 0.1781825292 },
            { 0.7581753966, 0.3265986324, 0.536554896, 0.1749635531 },
            { 0.722329618, 0.3548285843, 0.5702602248, 0.1647418427 },
            { 0.7263484574, 0.3804682396, 0.5418790079, 0.1844694495 },
            { 0.7591654715, 0.3718361493, 0.5112747053, 0.1549317289 },
            { 0.7630185276, 0.3352657167, 0.531800792, 0.1502915282 },
            { 0.7246023349, 0.3762358277, 0.5434517511, 0.195085244 },
            { 0.7692307692, 0.3076923077, 0.5384615385, 0.1538461538 },
            { 0.7392346163, 0.3758820083, 0.5262348116, 0.1879410041 },
            { 0.7889275246, 0.2892734257, 0.525951683, 0.1314879208 },
            { 0.73081412, 0.347436221, 0.5630862892, 0.1677278308 },
            { 0.7591170716, 0.3931141978, 0.4880038317, 0.1762236059 },
            { 0.7694544447, 0.3560162356, 0.5053133667, 0.1607815258 },
            { 0.7063189182, 0.3783851348, 0.5675777022, 0.1891925674 },
            { 0.756764973, 0.3522871426, 0.5349545499, 0.1304767195 },
            { 0.7644423782, 0.2712537471, 0.55483721, 0.1849457367 },
            { 0.7618518794, 0.3401124462, 0.530575416, 0.1496494763 },
            { 0.6985796007, 0.3788906309, 0.5683359464, 0.2131259799 },
            { 0.7701185383, 0.353497034, 0.5049957628, 0.1641236229 },
            { 0.7414330662, 0.2942194707, 0.5766701626, 0.1765316824 },
            { 0.7365989486, 0.3381109928, 0.5675434522, 0.1449047112 },
            { 0.7674169846, 0.3477358211, 0.5156082865, 0.155881575 },
            { 0.7678572553, 0.3490260251, 0.5119048369, 0.1628788117 },
        }
    }
}
```

```

        { 0.7646726946, 0.3148652272, 0.5397689609, 0.1574326136 },
        { 0.7408857634, 0.331739894, 0.5528998234, 0.18798594 },
        { 0.7335094873, 0.3545295855, 0.5501321155, 0.1833773718 },
        { 0.7866747377, 0.3588340909, 0.4830458915, 0.1380131119 },
        { 0.7652185485, 0.3339135485, 0.5286964517, 0.1530437097 },
        { 0.7724292478, 0.3370600354, 0.5196342212, 0.1404416814 },
        { 0.7643498123, 0.3558180161, 0.5139593566, 0.1581413405 },
        { 0.7077952503, 0.3185078626, 0.6016259627, 0.1887454001 },
        { 0.6933340942, 0.3851856079, 0.5777784118, 0.1925928039 },
        { 0.7152493551, 0.4053079679, 0.5364370163, 0.1907331613 },
        { 0.7545734059, 0.3491309788, 0.5293276131, 0.1689343446 },
        { 0.7753002086, 0.2830461079, 0.5414795108, 0.1599825827 },
        { 0.7299244279, 0.3910309435, 0.5344089561, 0.1694467422 }
    },
    //versicolor

    {
        { 0.653877471, 0.3425072467, 0.6227404486, 0.2594751869 },
        { 0.690525124, 0.3214513508, 0.6071858849, 0.2262065061 },
        { 0.7149140499, 0.3020763591, 0.5940835063, 0.2114534514 },
        { 0.6927679616, 0.3188931887, 0.6157937436, 0.1979337033 },
        { 0.6861902182, 0.3167031776, 0.61229281, 0.2322489969 },
        { 0.7095370786, 0.2800804257, 0.6161769366, 0.196056298 },
        { 0.6705411756, 0.3421128447, 0.6158031204, 0.2326367344 },
        { 0.7136655737, 0.2835109813, 0.6159031663, 0.1759723332 },
        { 0.714141252, 0.2664706164, 0.6182118301, 0.1918588438 },
        { 0.6919878754, 0.3459939377, 0.5862675055, 0.2402735678 },
        { 0.7156264473, 0.3523084048, 0.5614915202, 0.220192753 },
        { 0.7157654645, 0.3019635553, 0.5927432753, 0.2124928723 },
        { 0.7171814812, 0.3164035946, 0.5800732569, 0.2214825163 },
        { 0.6925517954, 0.3037507875, 0.6075015749, 0.24300063 },
        { 0.6776792359, 0.3271554932, 0.5958903626, 0.2804189942 },
        { 0.6958988737, 0.3479494368, 0.5762912548, 0.2500886577 },
        { 0.7061047399, 0.3258944953, 0.5974732415, 0.1955366972 },
        { 0.6929909912, 0.3419955541, 0.6029921612, 0.1979974261 },
        { 0.7060061789, 0.2383916968, 0.6326548876, 0.2108849625 },
        { 0.727125848, 0.2666128109, 0.6059382067, 0.181781462 },
        { 0.7055893432, 0.3272298403, 0.5828781531, 0.2351964477 },
        { 0.6830792286, 0.3415396143, 0.597694325, 0.2439568674 },
        { 0.7148654283, 0.2599510648, 0.6220257623, 0.185679332 },
        { 0.7312246431, 0.3133819899, 0.568730278, 0.2089213266 },
        { 0.6959560109, 0.3427843039, 0.5920819794, 0.2181354661 },
        { 0.7152945332, 0.3179086814, 0.5960787777, 0.1788236333 },
        { 0.7278519544, 0.3287073342, 0.5634982873, 0.2113118577 },
        { 0.7117121386, 0.3500223633, 0.5717031933, 0.210013418 },
        { 0.6959400158, 0.3044737569, 0.6089475138, 0.2283553177 },
        { 0.7308985537, 0.304541064, 0.5887793905, 0.1624219008 },
        { 0.7276615933, 0.2753314137, 0.5998291512, 0.1868320307 },
        { 0.7157899884, 0.344304045, 0.5798804969, 0.1812126553 },
        { 0.694177465, 0.3037026409, 0.6074052819, 0.2386235036 },
        { 0.7236600468, 0.3216266875, 0.5858200379, 0.1723000111 },
        { 0.6938541359, 0.2957411071, 0.6369808461, 0.1592452115 },
        { 0.6701748441, 0.3616816619, 0.5957109725, 0.2553047025 },
        { 0.6980479904, 0.3381169954, 0.5998849918, 0.1963259973 },
        { 0.7106690545, 0.3553345273, 0.5685352436, 0.2132007164 },
        { 0.7241525806, 0.325343913, 0.5667281066, 0.2203942637 }
    }
    //virginica
};

//rozmiar tablicy to: [3][10][4]
public static double[][][] flowerTest = {
    {
        { 0.8077956849, 0.5385304566, 0.2375869661, 0.0316782622 },
        { 0.8003330078, 0.5602331055, 0.208086582, 0.0480199805 },
        { 0.8609385733, 0.4400352708, 0.2487155878, 0.0573959049 },
        { 0.7860903755, 0.5717020913, 0.2322539746, 0.0357313807 },
        { 0.788894791, 0.5522263537, 0.2524463331, 0.0946673749 },
        { 0.766938972, 0.5714447242, 0.2857223621, 0.0601520762 },
        { 0.8221058465, 0.5138161541, 0.2397808719, 0.0513816154 },
        { 0.7772909267, 0.5791579454, 0.243855977, 0.0304819971 },
        { 0.7959478212, 0.5537028322, 0.2422449891, 0.034606427 },
        { 0.7983702483, 0.5573528148, 0.2259538439, 0.0301271792 }
    },
    //setosa

    {
        { 0.747141937, 0.3396099714, 0.5433759542, 0.1765971851 },
        { 0.7326039145, 0.3602970072, 0.552455411, 0.1681386033 },
        { 0.7626299404, 0.341868594, 0.525951683, 0.1577855049 },
        { 0.7698687947, 0.3541396456, 0.5081134045, 0.1539737589 },
    }
}

```



```

        { 0.7354428354, 0.3545885099, 0.5515821266, 0.1707278011 },
        { 0.7323961773, 0.3854716722, 0.5396603411, 0.1541886689 },
        { 0.7344604664, 0.3736728689, 0.5411813963, 0.1675085274 },
        { 0.7572810335, 0.3542120963, 0.5252110393, 0.1587847328 },
        { 0.7233711848, 0.3419572873, 0.5786969478, 0.1578264403 },
        { 0.7825805423, 0.3836179129, 0.4603414955, 0.1687918817 }
    },
    //versicolor
    {
        { 0.6999703739, 0.3238668894, 0.5850498648, 0.2507356563 },
        { 0.690525124, 0.3214513508, 0.6071858849, 0.2262065061 },
        { 0.691935021, 0.3256164805, 0.6003553859, 0.2340368453 },
        { 0.6891487079, 0.3394314531, 0.5862906918, 0.2571450403 },
        { 0.7215572479, 0.3230853349, 0.5600145805, 0.2476987567 },
        { 0.7296535933, 0.2895450767, 0.5790901534, 0.2200542583 },
        { 0.7165389871, 0.3307103017, 0.5732311897, 0.2204735345 },
        { 0.6746707199, 0.3699807173, 0.5876164334, 0.2502810735 },
        { 0.7333788618, 0.3294890538, 0.542062637, 0.2444596206 },
        { 0.6902591586, 0.3509792332, 0.5966646964, 0.2105875399 }
    }
    //virginica
};
}

```

```

package main;

import java.util.Random;

public class KohonenWTA {

    private int noi;        //ilość wejść
    private double[] w;     //wagi

    public KohonenWTA ( int numbers_of_inputs ) {
        noi = numbers_of_inputs;
        w = new double[noi];
        for ( int i = 0; i < noi; i++ )
            w[i] = new Random().nextDouble(); //wagi początkowe sa losowane w zakresie od 0 do 1
    }

    //uczenie poprzez zmniejszenie odległości między wektorem wag a zadany wektorem
    public void learn ( double[] x, double lr ) {
        for ( int i = 0; i < noi; i++ )
            w[i] += lr * ( x[i] - w[i] );
    }

    //zwraca wektor wag
    public double[] getW () {
        return w;
    }
}

```

```

package main;

public class MainKohonenWTA {

    private static double learningRate = 0.1;        //współczynnik uczenia się
    private static int numberOfInputs = 4;          //ilość wejść
    private static int numberOfNeurons = 200;        //liczba neuronów
    private static int numberOfFlowers = 3;          //liczba kwiatów
    private static int numberOfLearnSamples = 15;    //liczba danych uczących dla każdego kwiatu
    private static int numberOfTestSamples = 5;      //liczba danych testujących dla każdego kwiatu
    private static int learnLimit = 10000;          //maksymalny próg epok uczenia

    public static void main ( String[] args ) {

        KohonenWTA[] kohonens = new KohonenWTA[numberOfNeurons];
        for ( int i = 0; i < numberOfNeurons; i++ )
            kohonens[i] = new KohonenWTA( numberOfInputs );

        int ages = learn( kohonens );
        int winner;
    }
}

```



```

//zwraca zwycięzcę dla danego kwiatu
private static int getWinner ( KohonenWTA[] kohonens, double[] vector ) {

    int winner = 0;
    double minDistance = distanceBetweenVectors( kohonens[0].getW(), vector );

    //sprawdza który neuron jest zwycięzcą
    //miarą zwycięstwa jest odległość między wektorem wag neuronu a wektorem cech kwiatu
    for ( int i = 0; i < numberOfNeurons; i++ ) {
        if ( distanceBetweenVectors( kohonens[i].getW(), vector ) < minDistance ) {
            winner = i;
            minDistance = distanceBetweenVectors( kohonens[i].getW(), vector );
        }
    }

    return winner;
}

//zwraca odległość między zadanymi wektorami
public static double distanceBetweenVectors ( double[] vector1, double[] vector2 ) {

    double suma = 0.0;

    for ( int i = 0; i < vector1.length; i++ )
        suma += Math.abs( vector1[i] - vector2[i] ); //miara Manhattan

    return Math.sqrt( suma );
}
}

```

Bibliografia:

- S. Osowski – „Sieci neuronowe do przetwarzania informacji”
- https://en.wikipedia.org/wiki/Iris_flower_data_set
- <https://pl.khanacademy.org/computing/computer-programming/programming-natural-simulations/programming-vectors/a/vector-magnitude-normalization>